

姜羽扬

18136104181 | yuyangj@kth.se

AI 数据产品 / LLM 安全评测 / 数据生产链路 / 合成数据 / Agentic Workflow / Python

关注大模型训练与评测数据的生产、质量验收和自动化流程搭建，具备 AI 产品设计、模型评估、数据分析与基础工程实现能力。

教育经历

瑞典皇家理工学院 | 通信工程 硕士

2024年08月 - 2026年11月 | 瑞典斯德哥尔摩

东南大学 | 信息工程 本科

2020年09月 - 2024年06月 | 南京

工作经历

超级简历 | 产品经理实习生

2024年04月 - 2024年06月

- 围绕移动招聘与求职辅助场景开展竞品分析、用户需求研究和核心链路拆解，重点关注简历生成、岗位匹配、求职辅助等模块，输出竞品分析报告及产品优化方向。
- 识别用户在“高效生成简历”“明确求职方向”等场景下的核心痛点，参与一页纸方案梳理、需求讨论和产品方案迭代，提升对 AI 求职辅助产品场景的理解。
- 参与“性格测试 / 求职辅助”功能设计，完成高保真原型、结果页信息结构和关键交互流程；功能推送覆盖 7.5 万用户，结果页到达率 73.7%，带动 51 位用户完成职位投递。
- 参与社区功能数据分析，跟踪内容浏览、互动、转化与留存表现；发现使用过社区功能的用户次周留存率较未使用用户高 15%，为社区价值判断和后续产品优化提供依据。

中国科学院空天信息创新研究院 | Java 工程师实习生

2024年07月 - 2024年08月

- 参与智算框架相关研发工作，负责 Java 环境下部分模块的功能开发、接口逻辑实现、问题排查与功能验证，积累计算平台类系统的工程开发经验。
- 使用 Java 8 Lambda、Stream API 优化部分数据处理与业务逻辑代码，参与缓存机制与接口逻辑优化，并完成接口联调、异常排查和功能验证。

项目经历

LLM 安全评测数据生产与质量验收 Workflow MVP

产品设计 / 数据策略 / Python 原型搭建 | 2026年07月 - 至今

- 面向大模型安全评测场景，设计覆盖个人数据与隐私泄露、提示注入、有害行为、幻觉事实性、偏见公平性、不安全工具调用、数据合规与多模态上下文错配等 8 类风险的数据分类体系。
- 定义评测样本 schema，包含风险类型、业务场景、用户 prompt、期望行为、严重度、难度、是否拒答及 judge rubric 等字段，支撑样本生产、规则校验和后续人工抽检。
- 搭建“种子样本 -> 模板化合成样本 -> Schema 校验 -> 质量指标统计 -> 评估报告”的离线数据生产 Workflow，生成 32 条 MVP 样本并输出质量验收报告。
- 设计 schema 完整率、风险覆盖率、prompt 去重率、rubric 完整率、难度分布等质量门禁，并通过静态 demo 展示样本浏览、风险筛选和质量评估结果。
- 补充候选模型输出样例与 rubric judge 流程，对 baseline 与 safety workflow 两组输出进行评测，沉淀 bad case 归因和“评测结果 -> 数据动作 -> 补样策略”的数据飞轮思路。
- 项目链接: github.com/yuyangjungle/llm-safety-eval-workflow; yuyangjungle.github.io/llm-safety-eval-workflow/

文本预处理技术对大语言模型性能影响的研究

硕士毕业设计研究者 | 2025年01月 - 2026年01月

- 围绕 LLM/NLP 任务中的数据预处理与模型效果优化开展研究，评估不同文本预处理策略对模型性能、稳定性和泛化表现的影响。
- 基于 DepressionEmo 多标签数据集搭建完整实验流程，完成文本清洗、预处理配置设计、训练/验证集划分、模型微调、结果汇总与误差分析。
- 对 BERT、MPNet、GPT-2、T5 等模型，以及 Full Fine-tuning、LoRA、QLoRA 等参数高效微调方案进行对照实验，比较 Macro-F1、Micro-F1、Precision、Recall 等指标表现。
- 使用 Python、PyTorch、Transformers、Pandas 完成实验配置、结果统计和可视化分析，沉淀模型评估、数据质量分析和实验复盘方法。

地图开放平台智能检索：自然语言到地图 API 调用的 AI Agent 原型

产品设计 / AI Workflow 设计 / 原型搭建 | 2026年03月 - 至今

- 面向开放平台开发者接入场景，设计“自然语言需求 -> 意图解析 -> 结构化 API 参数 -> Web Service 调用 -> POI 结果 -> AI 推荐总结”的 Agentic Workflow，验证 AI Agent 降低 API 使用门槛的可行性。
- 将用户需求拆解为地点、关键词、半径、排序方式、使用场景等结构化字段，设计服务端 Agent Orchestrator，并调用高德开放平台 Web Service API 完成地理编码与周边 POI 检索。
- 围绕开放平台产品稳定性与安全性，设计服务端密钥保护、参数校验、模型解析失败 fallback、地图 API 调用失败 fallback 等机制，保障异常场景下流程可继续运行。

专业技能

- 产品能力：需求分析、竞品调研、PRD/MRD、用户流程设计、原型设计、数据分析、指标体系设计、跨团队协作
- AI / 数据：LLM、模型评测、合成数据、数据质量验收、Fine-tuning、LoRA、QLoRA、Prompt Workflow、Agentic Workflow、Pandas、数据清洗、实验结果分析
- 技术能力：Python、Java、JavaScript、React、Vite、API 调用、后端接口联调、缓存机制、参数校验、fallback 机制
- 技术理解：云计算、GPU 云服务、模型训练/推理流程、开发者工具、容器化、虚拟化、AI Infra